基于QLoRA的LLaMA-30B高效微调实战

一、实验介绍

1.1 实验概述

大型语言模型是一类参数数量庞大的神经网络模型,用于自然语言处理任务,如文本生成、语言理解等。LLaMA-30B是其中之一,拥有巨大的参数规模,但在进行微调时需要考虑内存占用和性能优化的问题。

微调是指在预训练模型的基础上,通过使用特定任务的数据集进行有监督学习,从而提高模型性能。在大型语言模型领域,微调是一种常见的技术,用于适应模型到特定领域或任务。然而,微调非常大的模型非常昂贵;以LLaMA 65B 参数模型为例,常规的 16 bit微调需要超过 780 GB 的 GPU 内存。

LoRA(Low-Rank Adaptation)是一种模型微调技术,通过低秩适应层实现大型语言模型的微调。QLoRA则是在此基础上提出的量化微调方法,能够在极低的比特数下实现模型微调,降低内存占用,并首次证明了可以在不降低任何性能的情况下微调量化为 4 bit 的模型。

1.2 实验目标

- 了解QLoRa的微调方式
- 了解大模型的训练和推理过程

1.3 预备知识

- 了解大语言模型的基本原理。
- 了解LoRa和QLoRa的基本原理。
- 掌握python和pytorch的基本使用。

二、实验内容

2.1 实验准备

当前云桌面实验环境中,已准备好了下述所有的实验材料。

2.1.1 环境准备

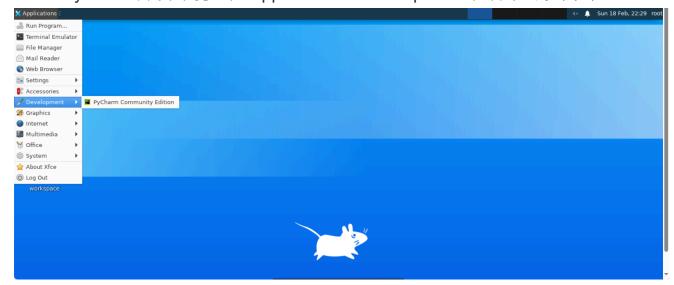
• 操作系统: Ubuntu20.04

• CPUs: 1个节点, 32核CPU, 128GB 内存

• GPUs: 1张A40, 40GB显存

• Python: 3.9, 所需依赖提供在requirements.txt中

• IDE: PyCharm开发环境,在"applocation->development"栏目下可以找到



2.1.2 数据集准备

- 数据集直接使用alpaca-lora项目提供的alpaca_data.json、 alpaca_data_cleaned_archive.json或alpaca_data_gpt4.json
- 数据集在实验目录下

2.1.3 模型准备

- 实验提供转换好的LLaMA-30B大模型的Huggingface Transformers格式,可直接进行实验
- 大模型位置在"/mnt/model/llama-30b9078/"

2.2 模型微调

在实验中,我们将使用QLoRA进行微调。以下是微调的基本命令:

```
python qlora.py \
   --dataset ./"mini_data.json" \
   --model_name_or_path "/mnt/model/llama-30b9078/" \
   --output_dir "llama-30b-qlora" \
   --per_device_train_batch_size 1 \
   --max_steps 1000 \
   --save_total_limit 2
```

2.3 模型权重合并

合并微调后的权重是为了优化模型的推理性能。下面是合并权重的代码:

```
import os
import torch
import peft
from peft import PeftModel
from transformers import LlamaForCausalLM, LlamaTokenizer
base_model_path = "/mnt/model/llama-30b9078/"
lora_model_path = "llama-30b-qlora/checkpoint-2/adapter_model/"
output_dir = "llama-30b-merge"
# Original method without offloading
base_model = LlamaForCausalLM.from_pretrained(
        base_model_path,
        #load_in_8bit=False,
        torch_dtype=torch.bfloat16,
        device_map={"": "cpu"},
)
lora model = PeftModel.from pretrained(
        base_model,
        lora_model_path,
        device_map={"": "cpu"},
        #torch_dtype=torch.float16,
)
tokenizer = LlamaTokenizer.from_pretrained(base_model_path)
if base_model.get_input_embeddings().weight.size(0) != len(tokenizer):
        base_model.resize_token_embeddings(len(tokenizer))
        print(f"Extended vocabulary size to {len(tokenizer)}")
print(f"Merging with merge_and_unload...")
base_model = lora_model.merge_and_unload()
tokenizer.save_pretrained(output_dir)
print("Saving to Hugging Face format...")
LlamaForCausalLM.save_pretrained(base_model, output_dir)
```

2.4 模型推理

为了比较不同推理方式的效果,我们提供了三种推理方式的代码,分别是合并后的权重文件推理、不合并权重文件直接推理和使用merge and unload()方法合并权重推理。

2.4.1 用合并后的权重文件推理

```
from transformers import AutoModelForCausalLM, LlamaTokenizer
import torch
model id = "/mnt/model/llama-30b9078/"
merge_model_id = "llama-30b-merge"
model = AutoModelForCausalLM.from_pretrained(merge_model_id, load_in_4bit=True,
device map="auto")
tokenizer = LlamaTokenizer.from_pretrained(model_id)
device = torch.device("cuda:0")
text = "Hello, my name is "
inputs = tokenizer(text, return_tensors="pt").to(device)
outputs = model.generate(**inputs, max_new_tokens=20, do_sample=True, top_k=30,
print(tokenizer.decode(outputs[0], skip_special_tokens=True))
print("\n-----\nInput: ")
line = input()
while line:
 inputs = tokenizer(line, return tensors="pt").to(device)
 outputs = model.generate(**inputs, max_new_tokens=20, do_sample=True, top_k=30,
top_p=0.85)
 print("Output: ",tokenizer.decode(outputs[0], skip_special_tokens=True))
 print("\n----\nInput: ")
 line = input()
```

```
Input:
Hello, Who are you?
Output: Hello, Who are you? Hello, I am a person in the room. I have the ability to read. And if you

Input:
What's CourseGrading LLM platform used for?
Output: What's CourseGrading LLM platform used for?
We provide a very wide range of legal services to businesses, families and individuals. For business

Input:
What's CourseGrading platform?
Output: What's CourseGrading platform?
Output: What's CourseGrading platform?
23. What was your first name?
```

2.4.2 不合并权重文件直接推理

```
from transformers import AutoModelForCausalLM, LlamaTokenizer
import torch
from peft import PeftModel
model id = "/mnt/model/llama-30b9078/"
lora_weights = "llama-30b-qlora/checkpoint-2/adapter_model/"
model = AutoModelForCausalLM.from_pretrained(model_id, load_in_4bit=True,
device_map="auto")
model = PeftModel.from_pretrained(model, lora_weights,)
tokenizer = LlamaTokenizer.from_pretrained(model_id)
device = torch.device("cuda:0")
text = "Hello, my name is "
inputs = tokenizer(text, return_tensors="pt").to(device)
outputs = model.generate(**inputs, max_new_tokens=20, do_sample=True, top_k=30,
top_p=0.85)
print(tokenizer.decode(outputs[0], skip_special_tokens=True))
print("\n----\nInput: ")
line = input()
while line:
  inputs = tokenizer(line, return_tensors="pt").to(device)
  outputs = model.generate(**inputs, max_new_tokens=20, do_sample=True, top_k=30,
top_p=0.85)
  print("Output: ",tokenizer.decode(outputs[0], skip_special_tokens=True))
  line = input()
```

```
Input:
Hello, Who are you?
Output: Hello, Who are you?
Hey, you lookin@@@ to hire?
I@@@m a highly skilled

Input:
What's CourseGrading LLM platform used for?
Output: What's CourseGrading LLM platform used for?
1. How much does a 250 mg tablet of 10 m

Input:
What's CourseGrading platform?
Output: What's CourseGrading platform?
Output: What's CourseGrading platform?
Output: What's CourseGrading platform?
Output: What's CourseGrading platform? What is it for?
Output: What's the difference between a productivity hack and productivity
```

2.4.3 用merge_and_unload()方法合并权重推理

```
from transformers import AutoModelForCausalLM, LlamaTokenizer
import torch
from peft import PeftModel
model_id = "/mnt/model/llama-30b9078/"
lora_weights = "llama-30b-qlora/checkpoint-2/adapter_model/"
model = AutoModelForCausalLM.from_pretrained(model_id, load_in_4bit=True,
device map="auto")
model = PeftModel.from_pretrained(model,lora_weights,)
model = model.merge_and_unload()
tokenizer = LlamaTokenizer.from_pretrained(model_id)
device = torch.device("cuda:0")
text = "Hello, my name is "
inputs = tokenizer(text, return_tensors="pt").to(device)
outputs = model.generate(**inputs, max_new_tokens=20, do_sample=True, top_k=30,
top_p=0.85)
print(tokenizer.decode(outputs[0], skip_special_tokens=True))
print("\n----\nInput: ")
line = input()
while line:
  inputs = tokenizer(line, return_tensors="pt").to(device)
  outputs = model.generate(**inputs, max_new_tokens=20, do_sample=True, top_k=30,
top_p=0.85)
  print("Output: ",tokenizer.decode(outputs[0], skip_special_tokens=True))
  print("\n-----
  line = input()
```

三、实验任务

请完成以下2个实验任务,并撰写并提交Word版或PDF版实验报告。实验报告中至少需包含如下内容:

- 任务1的实现思路。
- 任务1的实现代码及详细说明。
- 任务1的运行截图及详细说明。
- 任务2的实现思路。
- 任务2的实现代码及详细说明。
- 任务2的运行截图及详细说明。
- 实验总结与感悟。

3.1 任务1: 不同推理方式的效果对比

任务1的目标是比较三种不同的推理方式,分别是合并后的权重文件推理、不合并权重文件直接推理以及使用merge_and_unload()方法合并权重推理。我们将通过以下步骤实现:

- 使用合并后的权重文件进行推理:加载模型时直接使用合并后的权重文件进行推理。
- 不合并权重文件直接推理: 加载模型时仍然使用微调前的原始权重文件进行推理。

- 使用merge_and_unload()方法合并权重进行推理: 在模型加载后,使用merge and unload()方法将权重合并并进行推理。
- 通过对比这三种方式的推理结果,评估它们在生成文本质量和性能方面的差异。

3.2 任务2: LoRA版微调和QLoRA版微调性能对比

任务2旨在比较LoRA版微调和QLoRA版微调在不同数据规模下的性能和加速比。我们将通过以下步骤实现:

- 使用LoRA进行微调: 使用LoRA方法对预训练模型进行微调。
- 使用QLoRA进行微调: 使用QLoRA方法对预训练模型进行微调。
- 调整数据规模: 在两种微调方法下,分别使用不同规模的数据集进行微调。
- 观察性能对比和加速比。